

Categoría	Modelo	Proveedor	Tipo	Local / Cloud	Tamaño / Contexto	Hardware Requerido	API / Costo	Uso Recomendado	Justificación (Tarea, Recursos, Privacidad, Costo, Modalidad)
Texto / Generalista	Llama 3.1 8B	Meta	LLM	Ambos	8B / 128k	>= 8GB VRAM	Open-weights / Gratis local	Chatbots locales, procesamiento de texto general	Privacidad total al ser local. Costo cero de API. Ideal si el hardware es limitado y la tarea no requiere conocimiento hiperespecializado. Modalidad texto rápida.
Texto / Generalista	Mixtral 8x7B	Mistral AI	MoE (LLM)	Ambos	47B total / 32k	>= 24GB VRAM (o RAM en Mac)	Open-weights / Pago por API	Tareas generales complejas con buen rendimiento local	Se justifica cuando hay datos sensibles que prohíben la nube, pero se requiere capacidad de razonamiento alta. Requiere gran inversión en hardware si es local.
Texto / Generalista	Claude 3.5 Sonnet	Anthropic	LLM	Cloud	Privado / 200k	N/A (Cloud)	API de pago	Procesamiento de documentos largos, análisis general	Se elige por su inmensa ventana de contexto (analizar libros enteros). Se asume el costo económico y la falta de privacidad de datos a cambio de no requerir hardware local.
Razonamiento	OpenAI o1-preview	OpenAI	LLM (Chain of Thought)	Cloud	Privado / 128k	N/A (Cloud)	API de pago (Alto)	Problemas lógicos, matemáticos y diseño de arquitectura	Se elige para tareas donde la latencia no importa pero la precisión algorítmica es crítica. Exige presupuesto y ceder datos a la nube.
Razonamiento	DeepSeek-R1 (Destill)	DeepSeek	LLM (Razonamiento)	Ambos	Variable (ej. 8B, 14B)	Depende del tamaño	Gratis local / API barata	Razonamiento matemático y lógico open-source	Alternativa si hay restricciones de presupuesto o si se requiere ejecutar inferencia local para tareas analíticas manteniendo la privacidad de la data.
Desarrollo de Software	Qwen2.5-Coder 7B	Alibaba	Coding LLM	Ambos	7B / 32k	>= 8GB VRAM	Gratis local	Autocompletado y experimentación en Vibe Coding	Perfecto para el lab: requiere poco hardware, mantiene el código privado, coste cero y es muy eficiente en tareas de programación unitarias.

Categoría	Modelo	Proveedor	Tipo	Local / Cloud	Tamaño / Contexto	Hardware Requerido	API / Costo	Uso Recomendado	Justificación (Tarea, Recursos, Privacidad, Costo, Modalidad)
Desarrollo de Software	GitHub Copilot (Codex)	Microsoft / OpenAI	Coding Assistant	Cloud	Privado / ~8k-32k	N/A (Integrado en IDE)	Suscripción de pago	Desarrollo ágil, refactorización de repositorios	Máxima comodidad al estar integrado. Se sacrifica privacidad del código (según el plan) y tiene costo, pero acelera drásticamente la implementación.
Desarrollo de Software	Codestral 22B	Mistral AI	Coding LLM	Local / API	22B / 32k	>= 16GB VRAM	Open-weights / Pago API	Generación de código compleja, revisión de PRs	Mejor calidad que modelos de 7B, pero exige GPU potente. Justificable para equipos corporativos que no pueden exponer su código en la nube.
Visión / Multimodalidad	LLaVA 1.5 7B	OSS	VLM	Local	7B / 4k	>= 8GB VRAM	Gratis local	Extracción de texto de imágenes, análisis visual básico	Garantiza privacidad total para procesar imágenes confidenciales (ej. documentos médicos/legales). Costo cero, pero limitado en razonamiento complejo comparado con cloud.
Visión / Multimodalidad	Gemini 1.5 Pro	Google	Multimodal nativo	Cloud	Privado / 2 Millones	N/A (Cloud)	API de pago	Análisis masivo de video, código e imágenes combinadas	Invencible para tareas de contexto masivo (ej. procesar un video de 1 hora). Obliga al uso cloud ya que no existe hardware local capaz de manejar 2M de tokens fácilmente.
Voz (STT/TTS)	Whisper v3	OpenAI	STT (Audio a Texto)	Ambos	1.5B (Large)	CPU o >= 8GB VRAM	Gratis local / API pago	Transcripción de reuniones confidenciales, subtulado	La mejor opción para transcribir audios de forma segura. Se puede correr en CPU (más lento) o GPU, justificando su ejecución local frente a APIs de pago por privacidad.

Categoría	Modelo	Proveedor	Tipo	Local / Cloud	Tamaño / Contexto	Hardware Requerido	API / Costo	Uso Recomendado	Justificación (Tarea, Recursos, Privacidad, Costo, Modalidad)
Voz (STT/TTS)	ElevenLabs	ElevenLabs	TTS (Texto a Audio)	Cloud	N/A	N/A (Cloud)	Pago por caracteres	Generación de voces hiperrealistas comerciales	El nivel de expresividad no tiene rival local accesible. Se justifica ceder los textos a la nube y pagar cuando el producto final (ej. un audiolibro) requiere máxima calidad humana.
Embeddings	Nomic Embed Text	Nomic AI	Embedding	Local	137M / 8k	< 2GB RAM	Gratis local	Búsqueda semántica (RAG) con privacidad	Esencial para buscar en documentos privados sin enviar datos a internet. Su bajísimo consumo de CPU/RAM lo hace ideal para correr en cualquier laptop.
Embeddings	text-embedding-3-large	OpenAI	Embedding	Cloud	Privado / 8k	N/A (Cloud)	Pago por millones de tokens	Indexación masiva de documentos en la nube	Extremadamente económico y fácil de escalar. Se justifica cuando la infraestructura local no soporta indexar millones de documentos y la privacidad de esos textos no es restrictiva.