


# Componente 0 — Mapa Mental de Fundamentos de IA

*Fundamentos de IA para el Desarrollo de Software Aumentado*

El mapa mental muestra la estructura de relaciones entre los cinco bloques conceptuales del laboratorio. Cada bloque se detalla en la tabla correspondiente con qué es, para qué sirve, un ejemplo y dónde se aplicará durante el desarrollo del laboratorio.



## Rama 1 — Fundamentos

| Concepto                     | Qué es                                                                                                                      | Para qué sirve                                                                           | Ejemplo                                                             | Uso en el laboratorio                                                                                  |
|------------------------------|-----------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------|---------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------|
| Inteligencia Artificial (IA) | Campo de la computación que busca que sistemas realicen tareas que normalmente requieren inteligencia humana.               | Automatizar tareas cognitivas: razonar, reconocer patrones, tomar decisiones.            | Un sistema que reconoce voz y responde preguntas.                   | Paraguas conceptual bajo el que se ubican todos los modelos usados en Ollama, LM Studio y Vibe Coding. |
| Machine Learning (ML)        | Subcampo de la IA donde el sistema aprende patrones a partir de datos en vez de reglas programadas a mano.                  | Resolver tareas donde las reglas son difíciles de codificar (clasificación, predicción). | Un modelo que predice el precio de una acción con datos históricos. | Base teórica del Componente 4 (predicción de series temporales).                                       |
| Deep Learning                | Subcampo del ML basado en redes neuronales de múltiples capas que aprenden representaciones complejas de datos crudos.      | Resolver tareas de alta complejidad (texto, imagen, audio) donde el ML clásico no basta. | Un modelo que genera texto coherente a partir de una instrucción.   | Tecnología detrás de todos los LLM que se ejecutarán en el laboratorio.                                |
| Redes neuronales             | Estructura matemática inspirada en el cerebro: capas de neuronas artificiales conectadas que ajustan sus pesos al entrenar. | Servir de bloque de construcción de los modelos de Deep Learning.                        | Una red convolucional que clasifica imágenes.                       | Entender por qué los modelos 'aprenden' y por qué su salida no es 100% determinística.                 |
| Transformers                 | Arquitectura de red neuronal basada en                                                                                      | Ser la base de prácticamente todos los                                                   | La arquitectura detrás de GPT, Llama y                              | Arquitectura de los modelos que se                                                                     |

| Concepto              | Qué es                                                                                                                | Para qué sirve                                                         | Ejemplo                 | Uso en el laboratorio                                             |
|-----------------------|-----------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------|-------------------------|-------------------------------------------------------------------|
|                       | mecanismos de atención que procesa secuencias completas en paralelo.                                                  | LLM modernos.                                                          | Gemini.                 | descargarán en Ollama/LM Studio.                                  |
| Modelos fundacionales | Modelos de gran escala entrenados con datos generales, adaptables luego a tareas específicas sin entrenar desde cero. | Servir como punto de partida reutilizable para múltiples aplicaciones. | Llama 3, GPT-4, Claude. | Modelos generalistas comparados en el Componente 3 (Vibe Coding). |

## Rama 2 — Tipos de modelos

| Concepto                    | Qué es                                                                                                  | Para qué sirve                                                   | Ejemplo                                   | Uso en el laboratorio                                                                             |
|-----------------------------|---------------------------------------------------------------------------------------------------------|------------------------------------------------------------------|-------------------------------------------|---------------------------------------------------------------------------------------------------|
| LLM (Large Language Model)  | Modelo de lenguaje de gran tamaño entrenado para entender y generar texto.                              | Tareas de lenguaje general: chat, resumen, generación de texto.  | Llama 3, GPT-4o.                          | Modelo generalista que se ejecutará en Ollama.                                                    |
| SLM (Small Language Model)  | Versión reducida de un LLM, con menos parámetros, optimizada para hardware limitado.                    | Ofrecer velocidad y bajo consumo sin depender de la nube.        | Phi-3, Gemma 2B.                          | Alternativa recomendada si el hardware del equipo es limitado.                                    |
| VLM (Vision-Language Model) | Modelo que combina comprensión de imágenes y texto.                                                     | Tareas donde se necesita 'ver' y razonar sobre lo visto.         | LLaVA, GPT-4V.                            | Categoría de visión/multimodalidad en la cartografía (Componente 1).                              |
| Modelos de código           | Modelos especializados en generar, explicar y depurar código fuente.                                    | Programación asistida.                                           | Code Llama, Qwen2.5-Coder, Codex.         | Se usan directamente en el Componente 2 (modelo local de código) y el Componente 3 (Vibe Coding). |
| Modelos multimodales        | Modelos que procesan y combinan más de un tipo de dato (texto, imagen, audio) en una sola arquitectura. | Tareas que integran distintas fuentes de información.            | Gemini, GPT-4o.                           | Contexto conceptual para la cartografía de modelos.                                               |
| Embeddings                  | Representación numérica (vector) del significado de un texto u otro dato, usada para medir similitud.   | Búsqueda semántica, clasificación y recuperación de información. | text-embedding-3-small, nomic-embed-text. | Relevante si la aplicación final implementa búsqueda o recuperación de contexto.                  |
| STT / TTS                   | Speech-to-Text (audio a texto) y Text-to-Speech (texto a audio).                                        | Habilitar interfaces de voz.                                     | Whisper (STT), ElevenLabs (TTS).          | Parte del ecosistema a mapear en la cartografía (categoría voz).                                  |

## Rama 3 — Funcionamiento

| Concepto   | Qué es            | Para qué sirve      | Ejemplo                | Uso en el laboratorio    |
|------------|-------------------|---------------------|------------------------|--------------------------|
| Parámetros | Valores numéricos | Estimar capacidad y | Un modelo '7B' tiene 7 | Criterio para elegir qué |

| Concepto                     | Qué es                                                                                                              | Para qué sirve                                                              | Ejemplo                                                                   | Uso en el laboratorio                                                            |
|------------------------------|---------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------|---------------------------------------------------------------------------|----------------------------------------------------------------------------------|
|                              | internos del modelo ajustados durante el entrenamiento; indican su 'tamaño'.                                        | requisitos de hardware del modelo.                                          | mil millones de parámetros.                                               | modelo correr en Ollama según el hardware disponible.                            |
| Tokens                       | Unidades mínimas de texto (palabras, subpalabras o caracteres) que procesa el modelo.                               | Medir el texto de entrada/salida y el costo en APIs.                        | La palabra 'corriendo' puede dividirse en 2 tokens.                       | Relevante al consumir APIs en el Componente 4, donde el costo se mide en tokens. |
| Ventana de contexto          | Cantidad máxima de tokens que el modelo puede 'recordar' en una solicitud.                                          | Saber cuánta información se le puede dar al modelo de una vez.              | Un modelo con ventana de 128k tokens procesa un documento largo completo. | Limita cuánto código o contexto se puede pasar en Vibe Coding.                   |
| Inferencia                   | Proceso de usar un modelo ya entrenado para generar una respuesta a una entrada nueva.                              | Diferenciarlo del entrenamiento, donde el modelo aprende.                   | Ollama generando una respuesta a un prompt.                               | Es lo que ocurre cada vez que se consulta un modelo local o cloud.               |
| Temperatura                  | Parámetro que controla la aleatoriedad de las respuestas del modelo.                                                | Ajustar el comportamiento del modelo según la tarea.                        | Temperatura 0 para código, 0.8 para escritura creativa.                   | Se puede ajustar al consumir modelos por API en el Componente 2.                 |
| Cuantización                 | Técnica que reduce la precisión numérica de los parámetros (ej. de 16 a 4 bits) para ocupar menos memoria.          | Ejecutar modelos grandes en hardware limitado, con leve pérdida de calidad. | Un modelo 'Q4_K_M' en Ollama está cuantizado a 4 bits.                    | Necesaria para correr modelos localmente en laptops sin GPU dedicada.            |
| Entrenamiento vs. inferencia | Entrenamiento: proceso costoso donde el modelo aprende de datos. Inferencia: uso posterior del modelo ya entrenado. | Entender qué ocurre realmente al 'usar' un modelo.                          | Entrenar Llama 3 toma semanas en GPU; usarlo en Ollama toma segundos.     | El equipo solo hará inferencia, nunca entrenamiento desde cero.                  |

## Rama 4 — Formas de uso

| Concepto         | Qué es                                                                                                        | Para qué sirve                                              | Ejemplo                                                                              | Uso en el laboratorio                                             |
|------------------|---------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------|--------------------------------------------------------------------------------------|-------------------------------------------------------------------|
| Modelo local     | Modelo descargado y ejecutado en el hardware propio, sin depender de internet.                                | Privacidad, control total, o funcionamiento sin conexión.   | Correr Llama 3 con Ollama en la laptop del equipo.                                   | Método central del Componente 2.                                  |
| Modelo cloud     | Modelo ejecutado en servidores remotos, consumido vía API o interfaz web.                                     | Obtener mayor capacidad de la que el hardware local ofrece. | GPT-4o vía API de OpenAI.                                                            | Se compara contra los modelos locales en el Componente 3.         |
| API              | Interfaz que permite a un programa enviar solicitudes a un modelo y recibir respuestas de forma programática. | Integrar IA dentro de aplicaciones reales.                  | API local de Ollama en <a href="http://localhost:11434">http://localhost:11434</a> . | Mecanismo exacto que se usará para consumir modelos desde Python. |
| Interfaz de chat | Aplicación gráfica de                                                                                         | Uso directo y                                               | La interfaz de LM                                                                    | Primer punto de                                                   |

| Concepto           | Qué es                                                                                       | Para qué sirve                                                               | Ejemplo                  | Uso en el laboratorio                                       |
|--------------------|----------------------------------------------------------------------------------------------|------------------------------------------------------------------------------|--------------------------|-------------------------------------------------------------|
|                    | conversación que envuelve a un modelo para interactuar sin programar.                        | exploratorio del modelo.                                                     | Studio o de ChatGPT web. | contacto para probar un modelo antes de consumirlo por API. |
| Open-weight        | Modelo cuyos parámetros están disponibles públicamente para descargar y ejecutar libremente. | Tener control, transparencia y ejecución local sin depender de un proveedor. | Llama 3, Mistral, Gemma. | Modelos que se pueden descargar y correr en Ollama.         |
| Modelo propietario | Modelo cuyos parámetros no son públicos; solo se accede vía API controlada por el proveedor. | Acceder a capacidad o calidad superior a cambio de no exponer el modelo.     | GPT-4o, Claude, Gemini.  | Representa la opción 'cloud coding' en el Componente 3.     |

## Rama 5 — Infraestructura

| Concepto        | Qué es                                                                                                                | Para qué sirve                                                                          | Ejemplo                                                         | Uso en el laboratorio                                                           |
|-----------------|-----------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------|-----------------------------------------------------------------|---------------------------------------------------------------------------------|
| CPU             | Procesador de uso general que ejecuta instrucciones de forma secuencial.                                              | Opción mínima para correr modelos pequeños o cuantizados, aunque más lento.             | Correr un modelo 3B cuantizado en un portátil sin GPU dedicada. | Entorno de ejecución probable si el equipo no cuenta con GPU.                   |
| GPU             | Procesador especializado en cálculos paralelos masivos.                                                               | Acelerar drásticamente la inferencia de modelos grandes.                                | Una NVIDIA RTX ejecutando un modelo 7B sin cuantizar.           | Si está disponible, reduce el tiempo de respuesta observado en el Componente 2. |
| RAM / VRAM      | Memoria del sistema (RAM) y de la tarjeta gráfica (VRAM) donde se cargan los parámetros del modelo.                   | Definir el límite práctico de qué tamaño de modelo se puede correr.                     | Un modelo 7B cuantizado necesita ~5-6 GB de RAM/VRAM.           | Debe registrarse como parte de la evidencia del Componente 2.                   |
| Ollama          | Herramienta que permite descargar, ejecutar y exponer modelos de lenguaje localmente vía una API sencilla.            | Simplificar la ejecución local de LLM sin configuración compleja.                       | ollama run llama3                                               | Herramienta obligatoria del Componente 2.                                       |
| LM Studio       | Aplicación con interfaz gráfica para descargar, ejecutar y probar modelos locales, con opción de exponerlos como API. | Alternativa visual a Ollama para explorar modelos antes de integrarlos por código.      | Descargar un modelo GGUF desde la interfaz de LM Studio.        | Herramienta obligatoria del Componente 2, en paralelo con Ollama.               |
| Servicios cloud | Infraestructura de terceros que aloja y ejecuta modelos, accesible por API paga o con límites gratuitos.              | Usarse cuando se necesita un modelo más potente del que el hardware local puede correr. | API de OpenAI usada para el 'cloud coding' del Componente 3.    | Referencia comparativa frente a los modelos locales.                            |